Machine Learning & Scikit-Learn

Day3. 분류

분류

- 분류(Classification)
  - 둘 이상의 이산적인 범주로 레이블을 예측하는 분야
  - 오늘날의 활용 분야
    - ✓ 스팸 필터링
    - ✓ 언어 분류
    - ✓ 문서 유사도 분석
    - ✓ 필기체 문자 인식
    - ✓ 사기 판단(fraud detection)
  - 방법론
    - ✓ Naive Bayes, Decision Tree, Logistic Regression, K-Nearest Neighbors, SVM(Support Vector Machine)

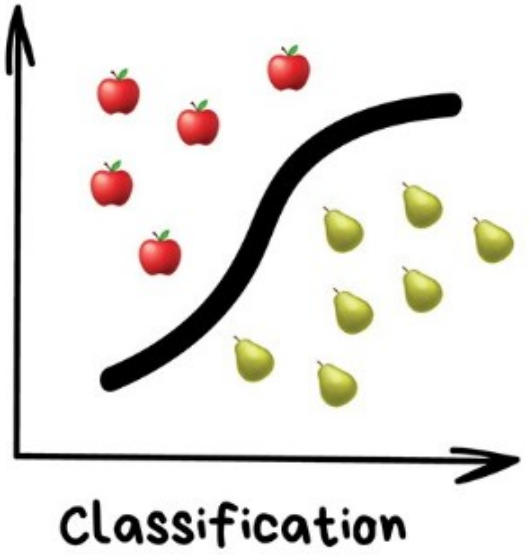

#1

로지스틱회귀분석

회귀 모델 vs. 분류 모델

	회귀 모델	분류 모델
목적	• 레이블된 학습 데이터를 가지고 특성(feature)과 레이블의 관계를 함수식으로 표현하는 것	• 그룹명(레이블)이 적힌 학습 데이터로 학습→새로 입력된 데이터가 속한 그룹을 찾아내는 것
결과값	• 데이터 세트 범위 내의 값(어떤 값이 나올지 예상하지 못하기 때문에 예측모델이라함)	• 학습 데이터 레이블 중 하나
종류	• 선형 회귀 • 로지스틱 회귀: 범주형 결과값	• kNN • SVM

회귀분석-(2) 로지스틱회귀

2) 로지스틱 회귀 분석(logistic regression)

- 적용 분야:
  - ✓ 종속변수가 예/아니오, 1/0, 합격/불합격, 구매/비구매 같은 범주형(categorical)으로 표현되는 경우
- 분류 모델임
- 회귀식 형태 : 로지스틱(logistic,=시그모이드 ,sigmoid) 함수

$$p(x)_{\beta_0,\beta_1} = \frac{e^{\beta_0+\beta_1 x}}{1+e^{\beta_0+\beta_1 x}}$$

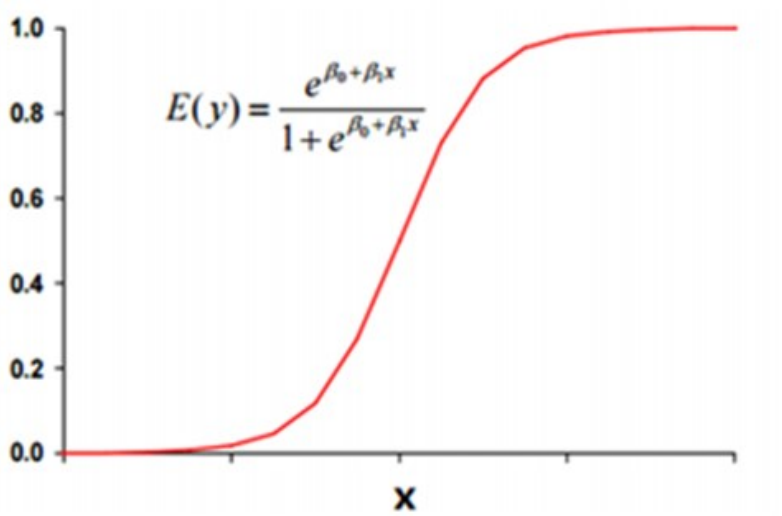

회귀분석-(2) 로지스틱회귀

2) 로지스틱 회귀 분석(logistic regression)

적용 분야 사례

X 데이터	Y 데이터
10	Pass (1)
9	Pass (1)
3	Fail (0)
2	Fail (0)
1	Fail (0)
5	???

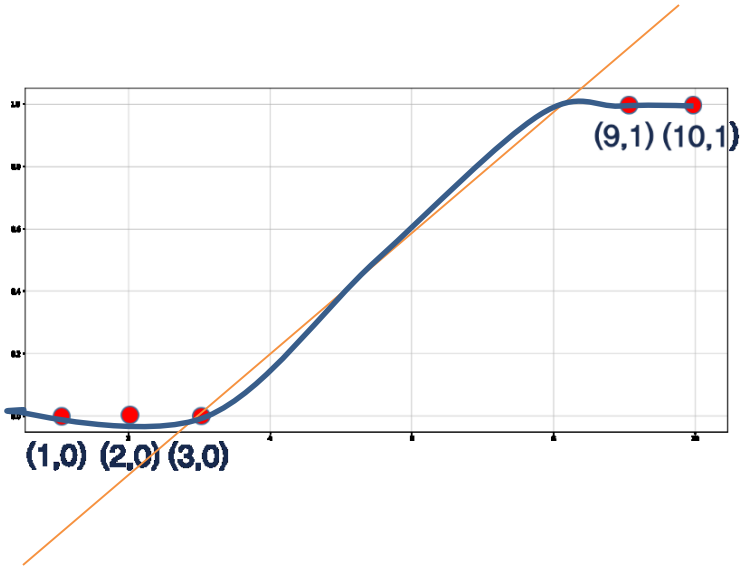

회귀분석-(2) 로지스틱회귀

2) 로지스틱 회귀 분석(logistic regression)

✓ 로지스틱 함수의 특성

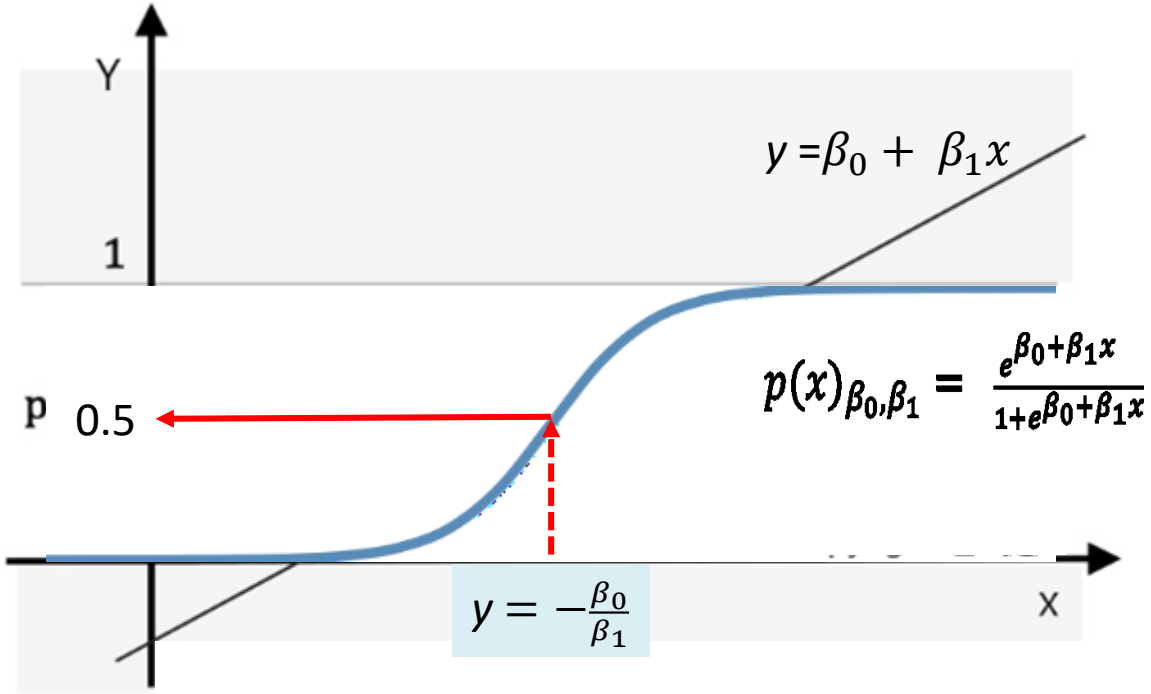

회귀분석-(2) 로지스틱회귀

2) 로지스틱 회귀 분석(logistic regression)

- 에러 함수 $$J(\theta) = \frac{1}{m}\sum_{i=1}^{m} Cost\left(h_\theta(x), y\right)$$

- 에러 함수의 최소값을 구하는 방법
  - ✓ 최대가능도법(maximum likelihood method)
  - ✓ Coordinate distance algorithm
  - ✓ Stochastic average gradient descent algorithm
  - ✓ Newton method
  - ✓ BFGS(Broyden-Fletcher-Goldfarb-Shanno)
  - ✓ LBFGS(Limited memory BFGS)

회귀분석-(2) 로지스틱회귀

2) 로지스틱 회귀 분석(logistic regression)

- Coordinate distance algorithm
  - ✓ Scikit-learn에서 사용하는 방법
  - ✓ 편미분 사용하지 않음

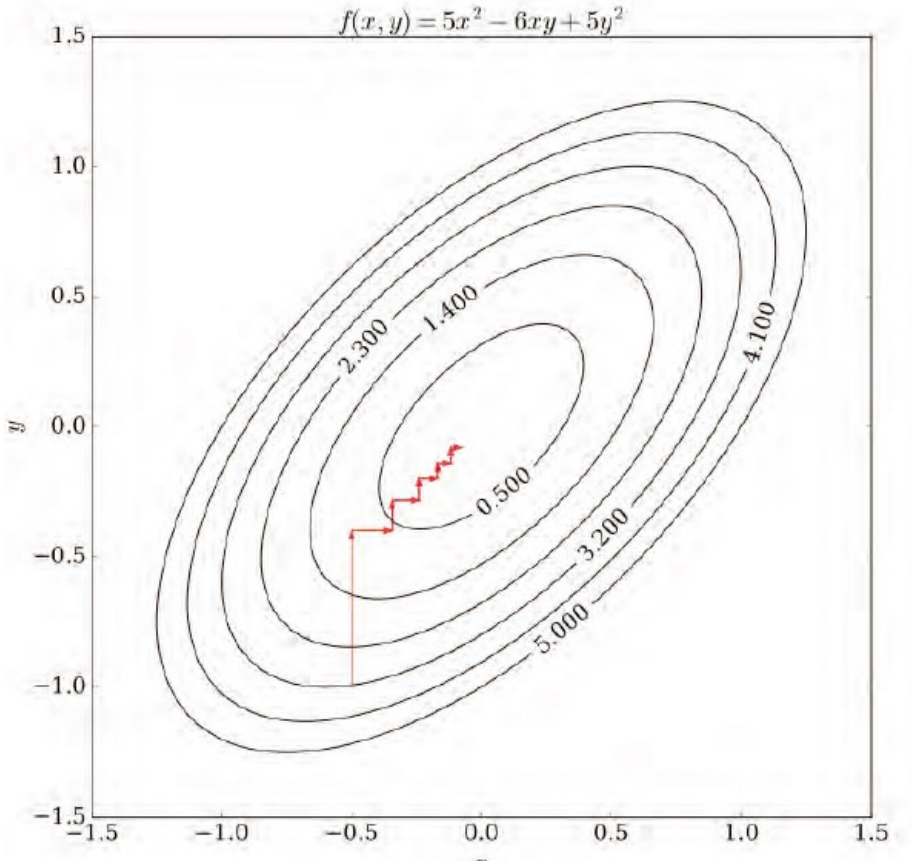

Scikit-learn 을 사용한 로지스틱 회귀

1. 데이터 준비

```
import pandas as pd
from sklearn.datasets import load_iris
import seaborn as sns; sns.set()
%matplotlib inline
```

```
iris = load_iris()
```

```
df = pd.DataFrame(iris.data, columns=iris.feature_names)
```

```
df['species'] = pd.Series(iris.target)
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
sepal length (cm)    150 non-null float64
sepal width (cm)     150 non-null float64
petal length (cm)    150 non-null float64
petal width (cm)     150 non-null float64
species              150 non-null int32
dtypes: float64(4), int32(1)
memory usage: 5.4 KB
```

Scikit-learn 을 사용한 로지스틱 회귀

2. 학습 시킬 데이터를 가지는 새로운 data frame 만들기

```
sl_df = pd.DataFrame()
```

```
sl_df['sepal_length'] = df['sepal length (cm)']
sl_df['species'] = df['species']
sl_df.info()
```

```
sl_df = sl_df[:100]
sl_df.info()
```

2 클래스만

```
sl_df.describe()
```

ame'>

at64
32

	sepal_length	species
count	100.000000	100.000000
mean	5.471000	0.500000
std	0.641698	0.502519
min	4.300000	0.000000
25%	5.000000	0.000000
50%	5.400000	0.500000
75%	5.900000	1.000000
max	7.000000	1.000000

Scikit-learn 을 사용한 로지스틱 회귀

2. 학습 시킬 데이터를 가지는 새로운 data frame 만들기

* 데이터 확인

```
sns.pairplot(sl_df, hue='species')
```

```
<seaborn.axisgrid.PairGrid at 0x9ea84b11d0>
```

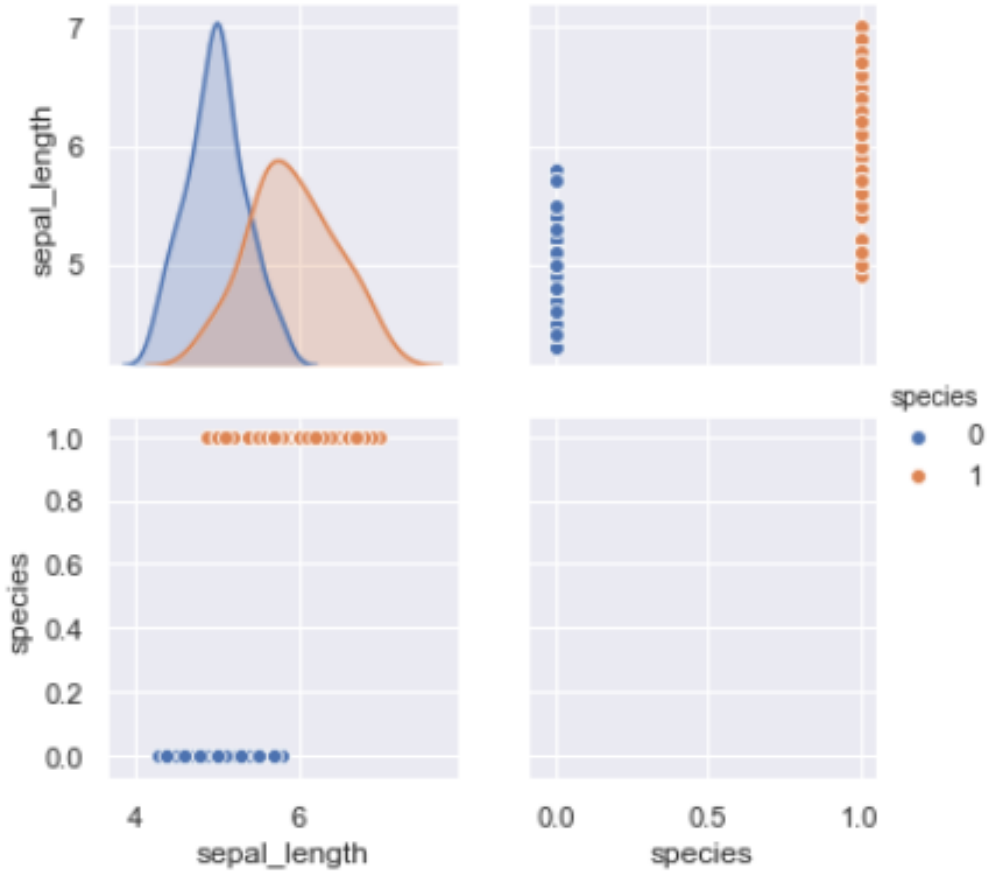

Scikit-learn 을 사용한 로지스틱 회귀

3. 학습 데이터와 테스트 데이터 나누기

```
# 학습 데이터, 테스트 데이터 나누기
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split( sl_df.iloc[:,:1],
                                                     sl_df.iloc[:, 1:], test_size=0.33)
```

Scikit-learn 을 사용한 선형회귀

4. 모듈 import

```
from sklearn.linear_model import LogisticRegression
```

5. 모델을 인스턴스화

```
lr = LogisticRegression()
```

Scikit-learn 을 사용한 선형회귀

6. 데이터를 특징과 대상 벡터로 배치

```
X = x[:, np.newaxis]
```

```
x.shape
```

```
(50,)
```

```
X.shape
```

```
(50, 1)
```

Scikit-learn 을 사용한 선형회귀

6. 주어진 데이터로 모델을 학습시키기

```
lr.fit(X_train, y_train)
```

Scikit-learn 을 사용한 선형회귀

7. 결과 확인: 데이터로 regression 모델의 그래프 그려보기

```
import seaborn as sns; sns.set()
sns.lmplot(x='sepal_length', y='species', data=sl_df, logistic=True)
```

```
<seaborn.axisgrid.FacetGrid at 0x9ea97429e8>
```

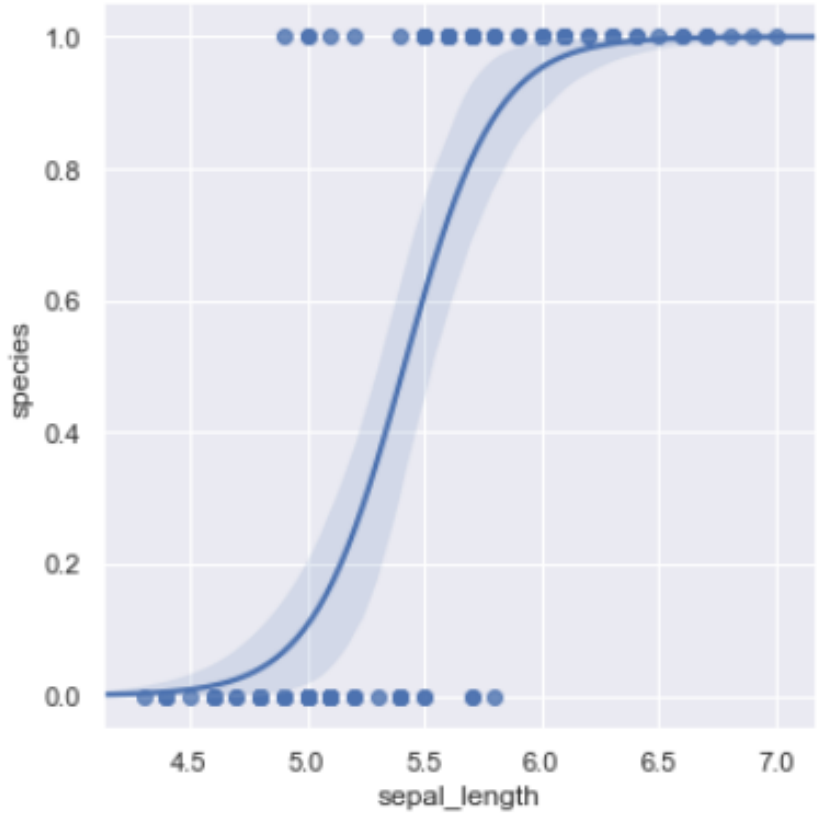

Scikit-learn 을 사용한 선형회귀

8. 학습된 데이터에 대한 성능 평가 하기

```
from sklearn.metrics import classification_report, confusion_matrix
```

```
print(confusion_matrix(y_train, lr.predict(X_train)))
```

```
[[27  8]
 [ 4 28]]
```

```
print(classification_report(y_train, lr.predict(X_train)))
```

```
              precision    recall  f1-score   support

           0       0.87      0.77      0.82        35
           1       0.78      0.88      0.82        32

    accuracy                           0.82        67
   macro avg       0.82      0.82      0.82        67
weighted avg       0.83      0.82      0.82        67
```

Scikit-learn 을 사용한 선형회귀

9. 테스트 데이터에 대한 성능 평가 하기

```
print(confusion_matrix(y_test, lr.predict(X_test)))
```

```
[[13  2]
 [ 1 17]]
```

```
print(classification_report(y_test, lr.predict(X_test)))
```

```
              precision    recall  f1-score   support

           0       0.93      0.87      0.90        15
           1       0.89      0.94      0.92        18

    accuracy                           0.91        33
   macro avg       0.91      0.91      0.91        33
weighted avg       0.91      0.91      0.91        33
```

#2

K-Nearest Neighbor

분류-(1) kNN 모델

- kNN(k-Nearrest Neighbor) 모델
  - 머신러닝 모델 중 가장 직관적이고 간단한 지도학습 모델
  - 유사성 척도(즉, 거리함수)기반 분류 방법
    - ✓ Euclidean distance $\sqrt{\sum_{i=1}^{k}(x_i - y_i)^2}$
  - 알고리즘
    1) 학습데이터가 주어짐 : 데이터를 클래스별로 저장해 놓음
    2) 분류할 새로운 데이터가 들어옴
       ① 입력 데이터와 가장 가까운 k개의 (학습)데이터를 찾음
       ② 찾은 k 개의 점이 속한 그룹 중에서
          데이터가 가장 많은 그룹을 입력데이터의 그룹으로 정함
          (k는 항상 홀수, 3~10 사이의 값이 최적)
  - 데이터 정규화 변환
    - ✓ Minmax scaling

분류-(1) kNN 모델

- (예) 나이(age)와 대출금(loan)으로 이 사람의 채무불이행(default)여부 판단

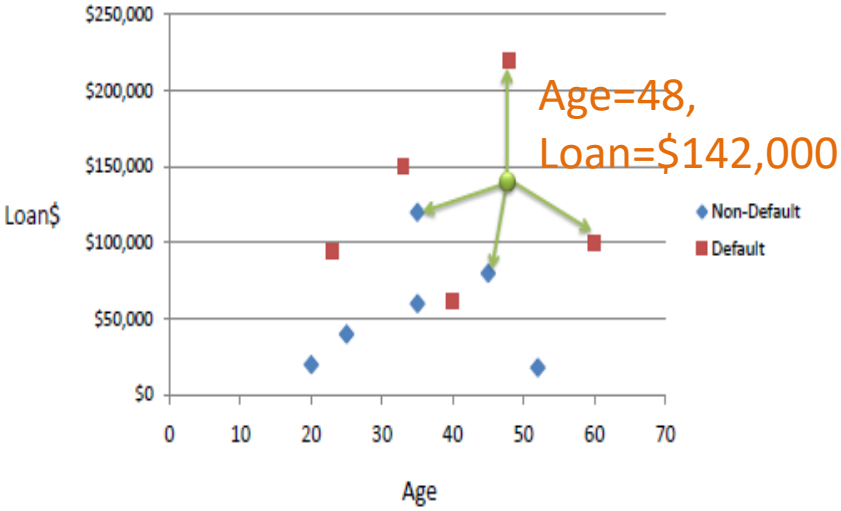

(1) Euclidean distance 계산

D = Sqrt[(48-33)^2 + (142000-150000)^2] = 8000.01 >> Default=Y

Age	Loan	Default	Distance	
25	$40,000	N	102000	
35	$60,000	N	82000	
45	$80,000	N	62000	
20	$20,000	N	122000	
35	$120,000	N	22000	2
52	$18,000	N	124000	
23	$95,000	Y	47000	
40	$62,000	Y	80000	
60	$100,000	Y	42000	3
48	$220,000	Y	78000	
33	$150,000	Y	8000	1
48	**$142,000**	**?**		

(2) K 결정

k=1 이면 Default = Y

k=3 이면 Default = Y (2 Y & 1 N)

Euclidean Distance

$$D = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

분류-(1) kNN 모델

- (예) 나이(age)와 대출금(loan)으로 이 사람의 채무불이행(default)여부 판단
  - ✓ 데이터 정규화 변환(scaling)의 필요성
    - Disatance는 Loan의 영향을 받음 (Age < 100 이고 40000< Loan 임)

(1) Euclidean distance 계산

Age	Loan	Default	Distance	
0.125	0.11	N	0.7652	
0.375	0.21	N	0.5200	
0.625	0.31	N	0.3160	1
0	0.01	N	0.9245	
0.375	0.50	N	0.3428	2
0.8	0.00	N	0.6220	
0.075	0.38	Y	0.6669	
0.5	0.22	Y	0.4437	
1	0.41	Y	0.3650	3
0.7	1.00	Y	0.3861	
0.325	0.65	Y	0.3771	
0.7	**0.61**	**?**		

K=1일 때, 결과 Default= N

K=3일 때, 결과 Default=N

Standardized Variable

$$X_s = \frac{X - Min}{Max - Min}$$

← Minmax scaling

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(1) 자료 준비하기

```
import pandas as pd
import numpy as np
from sklearn.datasets import load_iris
from sklearn.neighbors import KNeighborsClassifier
import matplotlib.pyplot as plt
import seaborn as sns; sns.set()
%matplotlib inline
```

```
iris = load_iris()
```

```
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df['species'] = pd.Series(iris.target)
```

Scikit-learn 을 사용한 kNN

- IRIS

```
def setcolor(value):
    color = []
    colors = ['r', 'g', 'b']
    for i in value.values:
        color.append(colors[i])
    return color
```

```
plt.scatter(x=df['petal length (cm)'], y=df['petal width (cm)'],
            color = setcolor(df['species']))
```

```
<matplotlib.collections.PathCollection at 0x9eaaa63dd8>
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

  (2) 모델 import 하기

```
from sklearn.neighbors import KNeighborsClassifier
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(3) kNN = 3으로 학습하기

```
from sklearn.neighbors import KNeighborsClassifier
```

```
column_train = ['petal length (cm)', 'petal width (cm)']
neigh_3 = KNeighborsClassifier(n_neighbors = 3, weights = 'distance')
```

```
neigh_3_train = neigh_3.fit(df[column_train], df['species'])
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(4) kNN = 3으로 학습한 결과를 새로운 점에 적용해 예측하기

```
new_data = np.array([2.5, 0.8]).reshape(1,-1)
```

```
# 학습 자료 출력
plt.scatter(x=df['petal length (cm)'], y=df['petal width (cm)'],
            color=setcolor(df['species']))
# 새 자료의 위치
plt.scatter(x=new_data[0,0], y=new_data[0,1], color='orange')
```

```
<matplotlib.collections.PathCollection at 0x9eaaae8358>
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(4) kNN = 3으로 학습한 결과를 새로운 점에 적용해 예측하기

```
neigh_3_class = neigh_3_train.predict(new_data)
```

```
print(neigh_3_class)
```

```
[1]
```

1번 클래스,
'g'color

Scikit-learn 을 사용한 kNN

- IRIS 더

(4) kNN

```
# 학습 자료 출력
plt.scatter(x=df['petal length (cm)'], y=df['petal width (cm)'],
            color=setcolor(df['species']))

# 새 자료의 위치
c3 = pd.DataFrame(np.array(neigh_3_class),columns=['c'])
col3 = c3['c']
plt.scatter(x=new_data[0,0], y=new_data[0,1],
             color=setcolor(col3))
```

```
<matplotlib.collections.PathCollection at 0x9eaafc55f8>
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(4) kNN = 7으로 kNN 알고리즘 학습하기

```
column_train = ['petal length (cm)', 'petal width (cm)']
neigh_7 = KNeighborsClassifier(n_neighbors = 7, weights = 'distance')
```

```
neigh_7_train = neigh_7.fit(df[column_train], df['species'])
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용하기

(5) kNN = 7으로 학습한 결과를 새로운 점에 적용해 예측하기

```
neigh_7_class = neigh_7_train.predict(new_data)
```

```
print(neigh_7_class)
```

```
[0]
```

Scikit-learn 을 사용한 kNN

- IRIS 데

(5) kNN

```
# 학습 자료 출력
plt.scatter(x=df['petal length (cm)'], y=df['petal width (cm)'],
            color=setcolor(df['species']))

# 새 자료의 위치
c7 = pd.DataFrame(np.array(neigh_7_class),columns=['c'])
col7 = c7['c']
plt.scatter(x=new_data[0,0], y=new_data[0,1],
             color=setcolor(col7))
```

```
<matplotlib.collections.PathCollection at 0x9eaab1c748>
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용: n_neighbor 모델의 accuracy 평가하기
  - Data를 train과 test로 나누어서 정확도 확인하기(1)

```
# n_neighbor  모델의 accuracy
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report, confusion_matrix
```

```
X_train, X_test, y_train, y_test = train_test_split(df[column_train],
                                                    df['species'], test_size=0.33)
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용: n_neighbor 모델의 accuracy 평가하기
  - Data를 train과 test로 나누어서 정확도 확인하기(2)

```
# n_neighbor=3로 학습시키기
neigh3 = KNeighborsClassifier(n_neighbors=3, weights='distance')
neigh3.fit(X_train, y_train)
```

```
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=3, p=2,
                     weights='distance')
```

Scikit-learn 을 사용한 kNN

- IRIS 데이터에 적용: n_neighbor 모델의 accuracy 평가하기
  - Data를 train과 test로 나누어서 정확도 확인하기(3)

```
# 학습시킨 모델의 정확도 테스트
print('------------ 3개의 이웃 데이터 -----------')
print(classification_report(y_test, neigh3.predict(X_test)))
```

```
------------ 3개의 이웃 데이터 -----------
              precision    recall  f1-score   support

           0       1.00      1.00      1.00        18
           1       0.92      0.92      0.92        12
           2       0.95      0.95      0.95        20

    accuracy                           0.96        50
   macro avg       0.96      0.96      0.96        50
weighted avg       0.96      0.96      0.96        50
```

#3

SVM(Support Vector Machine)

분류-SVM

- 서포트 벡터 머신(SVM: support vector machine)
  - 특징
    - ✓ 보편적으로 사용된 분류 머신 러닝 모델
    - ✓ 데이터가 2개의 그룹으로 분류될 때 사용
    - ✓ 주어진 데이터를 기반으로, 새로운 데이터가 어느 쪽인지 판단하는 모델을 만들고 그 경계를 구함

분류-SVM

- SVM 분류 예시

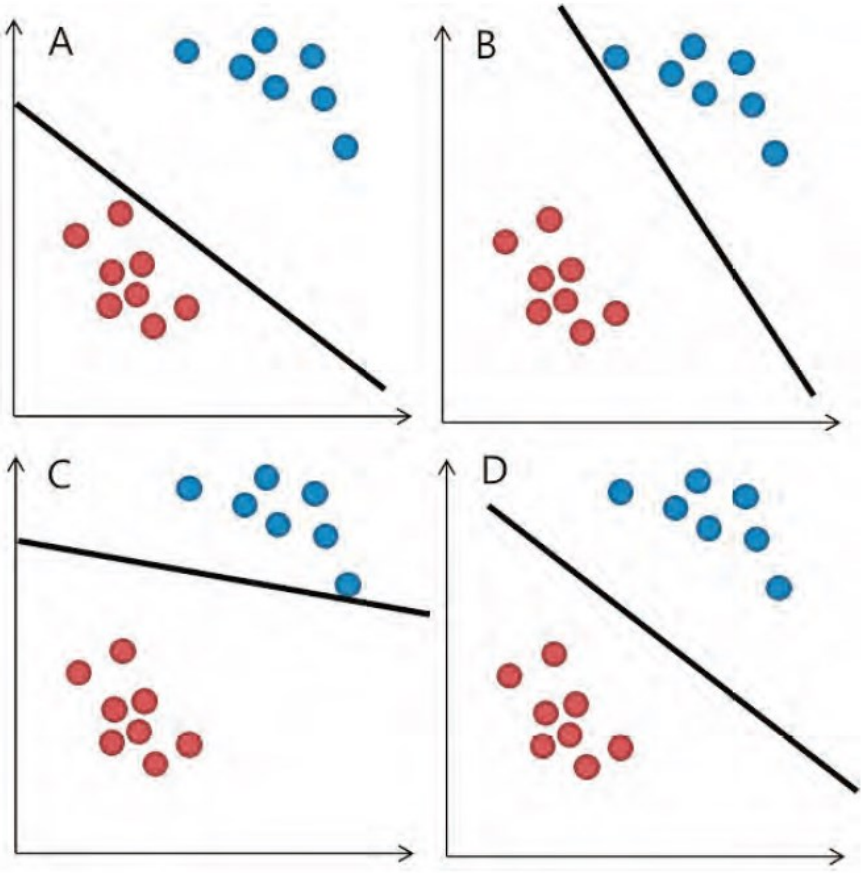

분류-SVM

- SVM 구성 요소
  - ✓ Hyper plane(초평면)
    - 두 그룹을 나누는 경계선
    - 특징(feature)의 수 보다 한 차원 낮음
  - ✓ 써포트 벡터(support vector)
    - 경계에서 가장 가까운 각 클래스의 데이터의 점
  - ✓ Margin
    - 초평면과 써포트 벡터까지의 수직 거리

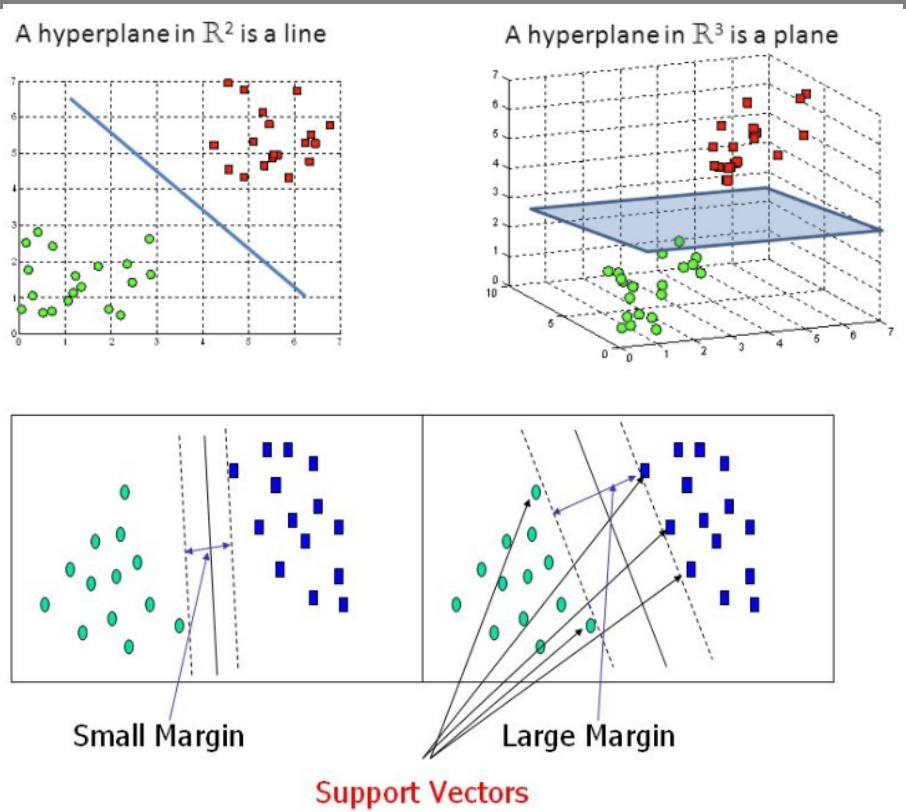

분류-SVM

- 서포트 벡터 머신(SVM: support vector machine)
  - SVM의 목표
    ① 벡터 공간에서 학습 데이터가 속한 2개의 그룹을 분류하는 선형 분리자를 찾음.
    (2개의 그룹을 가장 멀리 구분할 수 있는 선형 분리자)
    ② 필요시, 선형 분류가 불가능한 현재 공간을 (한 차원 높은 공간으로 변환하여)
    선형 분류가 가능하게 분포되는 공간으로 변환하여 분리함

분류-SVM

- 서포트 벡터 머신(SVM: support vector machine)
  - SVM의 목표
    - ① 벡터 공간에서 학습 데이터가 속한 2개의 그룹을 분류하는 선형 분리자를 찾음.
      (2개의 그룹을 가장 멀리 구분할 수 있는 선형 분리자)

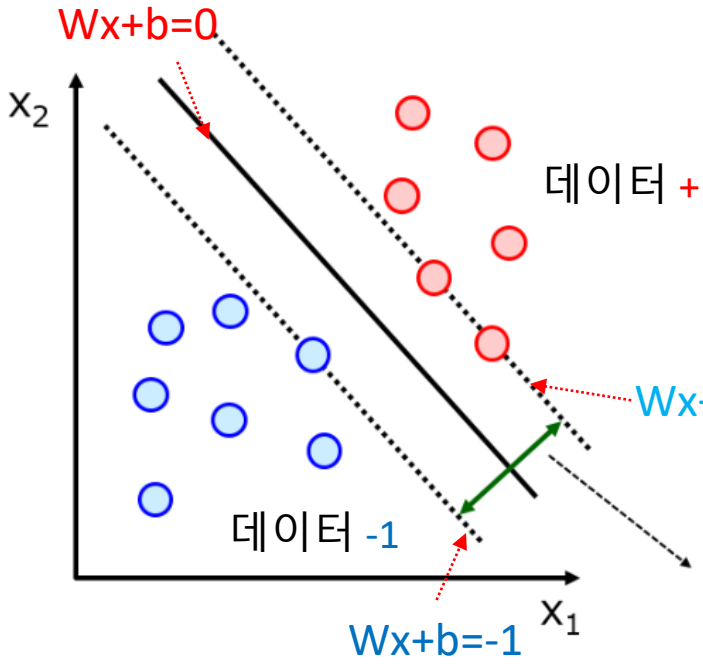

$$f(x_1, x_2) = w_1 x_1 + w_2 x_2 + b$$
$$= \mathbf{x}\mathbf{w} + b$$

$$\mathbf{w}^* = \sum_{i=1}^{n} \lambda_i y_i \mathbf{x}_i,$$

$$b^* = \frac{1}{|SV|} \sum_{SV} (y_i - \sum_{i=1}^{n} \lambda_i y_i \mathbf{x}_i^T \mathbf{x}_j)$$

$$\text{Margin} = \frac{2}{\|\mathbf{w}\|} = \frac{2}{\sqrt{w_1^2 + w_2^2}}$$

- 새로운 점 p에 대한 예측 $w^{*T} p + b^* = (\sum_{i=1}^{n} \lambda_i y_i x_i)^T p + b^*$

분류-SVM

- 서포트 벡터 머신(SVM: support vector machine)
  - 소프트 마진(soft margin)

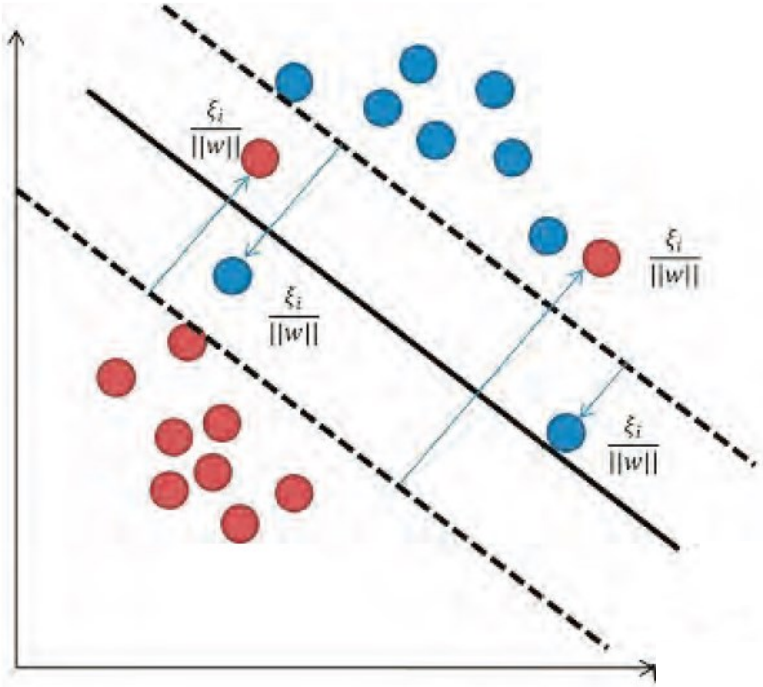

분류-SVM

- 서포트 벡터 머신(SVM: support vector machine)
  - SVM의 목표
    - ② 필요시, 선형 분류가 불가능한 현재 공간을 (한 차원 높은 공간으로 변환하여) 선형 분류가 가능하게 분포되는 공간으로 변환하여 분리함
      - 커널 트릭(kernel trick)

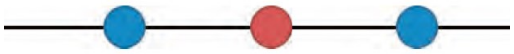

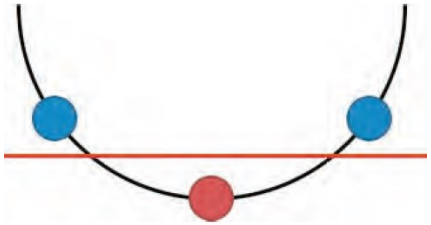

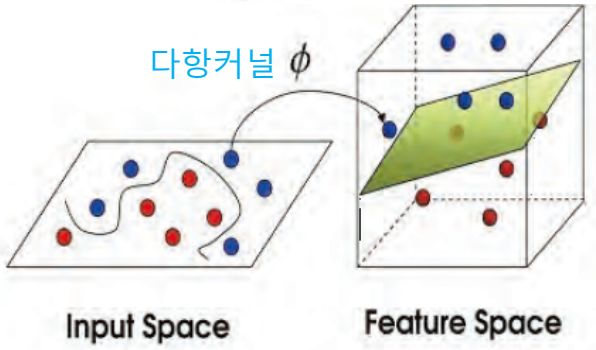

① 다항 커널(polynomial kernel)

$$K(x_i, x_j) = (x_i \cdot x_j + 1)^p$$

① 가우시안 커널(RBF kernel)

$$K(x_i, x_j) = e^{-||x_i - x_j||^2 / 2\sigma^2}$$

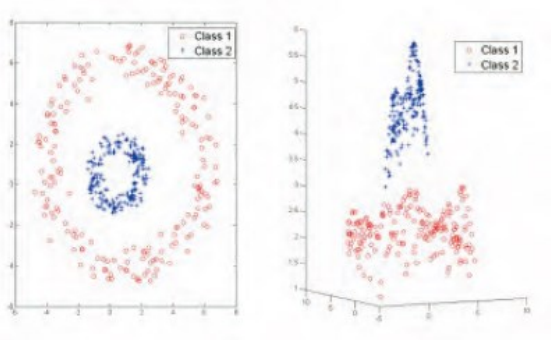

Scikit-learn을 활용하여 SVM 구현하기

- 선형 SVM

(1) 선형 SVM 선언 및 학습

```
import numpy as np
from sklearn import svm
```

```
X = np.array([ [0,0], [1,1] ])
y = [0, 1]
```

```
LinearSVM = svm.LinearSVC()
LinearSVM.fit(X, y)
```

```
LinearSVC(C=1.0, class_weight=None, dual=True, fit_intercept=True,
          intercept_scaling=1, loss='squared_hinge', max_iter=1000,
          multi_class='ovr', penalty='l2', random_state=None, tol=0.0001,
          verbose=0)
```

Scikit-learn을 활용하여 SVM 구현하기

- 선형 SVM

(2) 선형 SVM 학습 결과 확인

```
LinearSVM.predict([[2,2]])
```

```
array([1])
```

```
print(LinearSVM.coef_[0])
print(LinearSVM.intercept_[0])
```

```
[0.58822994 0.58822994]
-0.4705748577631975
```

$$y = 0.59\,x_1 + 0.59\,x_2 - 0.47$$

Scikit-learn을 활용하여 SVM 구현하기

- 선형 SVM

(3) 선형 SVM의 초평면 그려보기

```
import matplotlib.pyplot as plt
from matplotlib import style
style.use("ggplot")
```

```
w = LinearSVM.coef_[0]
print(w)
b = LinearSVM.intercept_[0]
slope = -w[0] / w[1]
xx = np.linspace(0, 1.5)
yy = slope * xx - b/w[1]
h0 = plt.plot(xx, yy, 'k-', label='Hyperplane')
plt.scatter(X[:, 0], X[:,1], c=y)
plt.legend()
plt.show()
```

```
[0.58822085 0.58822085]
```

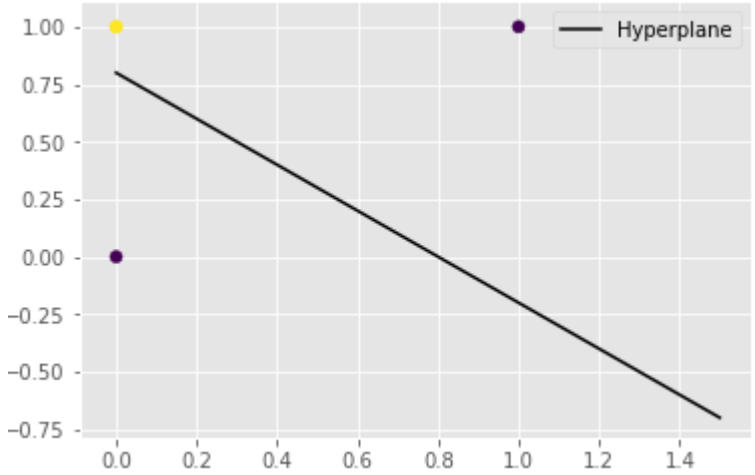

Scikit-learn을 활용하여 SVM 구현하기

- 비선형 SVM : XOR 문제

(1) XOR 데이터 준비

```
import numpy as np
from sklearn import svm
import matplotlib.pyplot as plt
```

```
X = np.array([[0,0],[0,1],[0,1],[1,1]])
y = [0, 1, 1, 0]
```

Scikit-learn을 활용하여 SVM 구현하기

- 비선형 SVM : XOR 문제

(2) 비선형 SVM 선언 및 학습

```
SVM_XOR = svm.SVC()
SVM_XOR.fit(X, y)
```

```
C:₩Users₩cosmos₩Anaconda3₩lib₩site-packages₩sklearn₩svm₩base.py:193: Futu
'scale' in version 0.22 to account                    scaled features. Set gamm
  "avoid this warning.", FutureWar
```

3차원

```
SVC(C=1.0, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='auto_deprecated',
    kernel='rbf', max_iter=-1, probability=False, random_state=None,
    shrinking=True, tol=0.001, verbose=False)
```

'rbf' 커널 사용

Scikit-learn을 활용하여 SVM 구현하기

- 비선형 SVM : XOR 문제

(3) 새로운 데이터 대한 예측

```
test_data = np.array([[0.8, 0.8], [0.2, 0.9]])
SVM_XOR.predict(test_data)
```

```
array([0, 1])
```

Q & A